

# Executive Summary: Translating Data into Business Strategy

## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

### Executive Summary: Business Context, KPIs & Strategic Impact

### Resumen Ejecutivo: Contexto de Negocio, KPIs e Impacto Estratégico




EN:

- This report contains an end-to-end Machine Learning project focused on analyzing and predicting airline passenger satisfaction based on survey data from 129,880 customers. By implementing and optimization-tuning a Decision Tree classifier, this project identifies the operational features that hold the highest leverage over user sentiment.
- Build a predictive classification model to determine whether a future customer will be satisfied or dissatisfied with their flight experience, pinpointing the most critical drivers of satisfaction.

ES:

- Este informe contiene un proyecto de Machine Learning de extremo a extremo enfocado en analizar y predecir la satisfacción de los pasajeros de una aerolínea basándose en datos de encuestas de 129,880 clientes. Mediante la implementación y optimización de un clasificador de Árbol de Decisión, este proyecto identifica las características operativas con mayor impacto en el sentimiento de los usuarios.
- Construir un modelo de clasificación predictivo para determinar si un futuro cliente estará satisfecho o insatisfecho con su experiencia de vuelo, identificando los factores más críticos de la satisfacción.




#### Inflight Entertainment / Entretenimiento a Bordo.

EN:

- The Driver: Inflight entertainment is the primary statistical gateway for passenger sentiment.
- The Action: Allocate capital to upgrade older onboard screens, expand the digital media catalog, and ensure stable fleet-wide Wi-Fi streaming.

ES:

- El Factor Clave: El entretenimiento a bordo es el punto de entrada estadístico más crítico para el sentimiento del pasajero.
- La Acción: Asignar presupuesto para actualizar pantallas obsoletas, expandir el catálogo digital y asegurar streaming estable vía Wi-Fi.



#### Two-Pronged Strategy / Estrategia Dual

EN:

- The Action: Focus on two operational fronts depending on flight segment.
  - Economy: Protect Seat comfort aggressively if entertainment is low to prevent drop-offs.
  - Premium: Streamline Online booking to secure loyalty for tech-driven travelers.

ES:

- La Acción: Enfocar esfuerzos en dos frentes operativos según el segmento de vuelo.
  - Económico: Proteger la Comodidad del asiento si el entretenimiento es bajo para evitar caídas.
  - Premium: Optimizar la Reserva en línea para consolidar la lealtad de usuarios digitales.

#### CRM Deployment / Impacto en el CRM

EN:

- The Metric: The model achieves an exceptional 95.13% Precision in satisfaction labeling.
- The Strategy: Integrate into the CRM to auto-invite happy customers to premium tiers and deploy automated service recovery (miles, perks) to at-risk segments.

ES:

- La Métrica: El modelo alcanza una Precisión del 95.13% al etiquetar la satisfacción.
- La Estrategia: Integrar al CRM para invitar automáticamente a usuarios conformes a programas premium y activar compensaciones (millas, beneficios) en segmentos en riesgo.

# Executive Summary: Translating Data into Business Strategy

## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

### PROJECT: 10 The Nuts and Bolts of Machine Learning



#### Data Ingestion & Cleaning/ Carga y Limpieza de Datos

| Dataset Metric / Métrica del Dataset          | Value / Valor         | Data Type / Tipo de Dato | Model Impact / Impacto en el Modelo                                                                                                      |
|-----------------------------------------------|-----------------------|--------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| Total Volume / Volumen Total                  | 129,880 rows / filas  | —                        | EN: Robust sample space for decision tree training. / ES: Espacio muestral robusto para el entrenamiento del árbol.                      |
| Categorical Variables / Variables Categóricas | 4 columns / columnas  | object                   | EN: Require numeric encoding for scikit-learn compatibility. / ES: Requieren codificación numérica (encoding) para scikit-learn.         |
| Numerical Variables / Variables Numéricas     | 18 columns / columnas | int64                    | EN: Survey features (0-5 scale), flight distances, and delays. / ES: Características de la encuesta (escala 0-5), distancias y retrasos. |
| Missing Values / Datos Faltantes              | 393 nulls / nulos     | float64 (Arrival Delay)  | EN: Requires a targeted cleaning workflow prior to modeling. / ES: Requieren un flujo de limpieza antes de iniciar el modelado.          |
| Memory Footprint / Consumo de Memoria         | 21.8+ MB              | —                        | EN: Lightweight allocation, optimal for local and cloud runtimes. / ES: Carga ligera, óptima para procesamiento local y en la nube.      |

- EN:
- Dataset Profile: Ingested 129,880 rows across 22 columns (the Gender column was previously removed) with a memory footprint of 21.8+ MB.
  - Categorical Handling: Identified 4 object columns (satisfaction, Customer Type, Type of Travel, Class). These require numeric encoding as scikit-learn algorithms demand strictly numerical matrices.
  - Missing Value Detection: Revealed 393 null entries in Arrival Delay in Minutes (129,487 non-null rows). All other columns are 100% complete; a specific isolation or imputation workflow is required before modeling.
  - Numerical Target Features: The remaining 18 variables are correctly stored as integers (int64), representing customer survey metrics (0-5 scale), travel distances, and departure delays.
- ES:
- Perfil del Dataset: Carga de 129,880 filas y 22 columnas (la columna Género fue removida previamente) con un consumo de memoria de 21.8+ MB.
  - Manejo de Categóricos: Identificación de 4 columnas tipo objeto (satisfaction, Customer Type, Type of Travel, Class). Recomiendan codificación numérica ya que los algoritmos de scikit-learn exigen matrices estrictamente numéricas.
  - Detección de Valores Faltantes: Reveló 393 registros nulos en Arrival Delay in Minutes (129,487 filas no nulas). Las demás columnas están 100% completas; se requiere un flujo de imputación o eliminación antes de modelar.
  - Variables Numéricas Objetivo: Las 18 variables restantes están correctamente almacenadas como enteros (int64), representando métricas de la encuesta (escala 0-5), distancias y retrasos de salida.



#### Data Engineering & Class Balance / Ingeniería de Datos y Balance de Clases

| Feature / Variable                        | Unique Values / Valores Únicos                      | Distribution Count / Conteo de Distribución                                             | Modeling Treatment / Tratamiento para Modelado                                                         |
|-------------------------------------------|-----------------------------------------------------|-----------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|
| satisfaction (Target / Variable Objetivo) | 2 Levels / Niveles: ['satisfied', 'dissatisfied']   | Satisfied / Satisfechos: 71,087 (54.7%)<br>Dissatisfied / Insatisfechos: 58,793 (45.3%) | reliable metric. / ES: Variable objetivo bien balanceada. Valida la Exactitud como métrica confiable.  |
| Class (Ordinal / Variable Ordinal)        | 3 Levels / Niveles: ['Business', 'Eco Plus', 'Eco'] | Business: High / Alto   Eco Plus: Mid / Medio   Eco: Standard / Estándar                | EN: Requires Ordinal Encoding to preserve hierarchical value. / ES: Requiere Codificación Ordinal para |

- EN:
- Feature Analysis: Identified Class as an ordinal feature containing three distinct levels (Eco, Business, Eco Plus). This structure dictates an ordinal mapping strategy during the data encoding pipeline.
  - Target Balance Verification: Executed value\_counts() on the target variable satisfaction, revealing 71,087 satisfied vs. 58,793 dissatisfied records.
  - Methodological Impact: The dataset shows an optimal, natural distribution with no severe class imbalance. This guarantees the baseline model can be trained directly and validates Accuracy as a reliable overall performance metric.
- ES:
- Análisis de Variables: Identificación de Class como una variable ordinal con tres niveles distintos (Eco, Business, Eco Plus). Esta estructura define la estrategia de mapeo ordinal durante la fase de codificación de datos.
  - Verificación de Balance Objetivo: Ejecución de value\_counts() sobre la variable objetivo satisfaction, revelando 71,087 registros satisfechos frente a 58,793 insatisfechos.
  - Impacto Metodológico: El conjunto de datos presenta una distribución óptima y natural sin desbalance severo de clases. Esto garantiza que el modelo base puede entrenarse directamente y valida la Exactitud (Accuracy) como una métrica confiable de rendimiento general.

# Executive Summary: Translating Data into Business Strategy

## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

Data Quality & Integrity: Dimensions and 0.30% Null Value Management  
Calidad e Integridad de Datos: Dimensiones y Manejo del 0.30% de Valores Nulos



### Missing Data & Cleaning Drop / Diagnóstico y Limpieza de Nulos

| Pipeline Stage / Etapa del Flujo                         | Rows / Filas | Columns / Columnas | Data Quality Notes / Notas de Calidad de Datos                                                              |
|----------------------------------------------------------|--------------|--------------------|-------------------------------------------------------------------------------------------------------------|
| Initial Ingestion / Ingesta Inicial (df_original.shape)  | 129,88       | 22                 | ES: El dataset contiene 393 valores nulos en retraso de llegada.                                            |
| Post-Cleaning / Después de la Limpieza (df_subset.shape) | 129,487      | 22                 | EN: Dropped 393 rows (axis=0). Negligible 0.30% data loss. / ES: Eliminación de 393 filas (axis=0). Pérdida |



### Feature Engineering Pipeline| Flujo de Ingeniería de Características

| Feature / Variable    | Variable Type / Tipo de Variable   | Transformation Method / Método de Transformación | Numerical Mapping / Mapeo Numérico          |
|-----------------------|------------------------------------|--------------------------------------------------|---------------------------------------------|
| satisfaction (Target) | Binary Target / Objetivo Binario   | Dictionary Mapping / Mapeo Directo               | {'dissatisfied': 0, 'satisfied': 1}         |
| Class                 | Ordinal Feature / Variable Ordinal | Ordinal Encoding / Codificación Ordinal          | {'Eco': 0, 'Eco Plus': 1, 'Business': 2}    |
| Customer Type         | Nominal Feature / Variable Nominal | One-Hot Encoding (get_dummies)                   | drop_first=True (Creates binary indicators) |
| Type of Travel        | Nominal Feature / Variable Nominal | One-Hot Encoding (get_dummies)                   | drop_first=True (Creates binary indicators) |

EN:  
Prior to model training, a rigorous *feature engineering pipeline* was executed, specifically focusing on *categorical variable transformation*. Since *decision tree classifiers* in *scikit-learn* require strictly *numerical input matrices*, the conversion from text to numbers was performed using distinct strategies tailored to the mathematical nature of each attribute. This approach ensures both the *preservation of business hierarchies* and the statistical stability of the model.

- *Ordinal Encoding*: Applied specifically to the *Class* column to assign logical *hierarchical weights* (*Eco: 0, Eco Plus: 1, Business: 2*). This method allows the *algorithm to mathematically* interpret the inherent value order across different travel classes.
- *Binary Mapping*: Implemented on the target variable *satisfaction* to transform *text labels* into a structured *binary format* (*dissatisfied: 0, satisfied: 1*), optimizing the classifier's internal cost function calculation.
- *One-Hot Encoding (Dummy Variables)*: Deployed across the remaining *nominal features* (*Customer Type* and *Type of Travel*) using the *pd.get\_dummies(..., drop\_first=True)* function. Strategically *dropping* the first category (*drop\_first*) mathematically prevents the *dummy variable trap* (*multicollinearity* among engineered indicators).

ES:  
Antes de proceder con el *entrenamiento del modelo*, se implementó un flujo riguroso de *ingeniería de características* (feature engineering) enfocado en la *transformación de variables categóricas*. Dado que los clasificadores basados en *árboles de decisión* dentro de *scikit-learn* requieren matrices estrictamente *numéricas*, la *conversión de texto a número* se ejecutó utilizando enfoques diferenciados según la naturaleza matemática de cada atributo, garantizando la *preservación de jerarquías de negocio* y la estabilidad estadística del modelo.

- *Codificación Ordinal* (Ordinal Encoding): Aplicado específicamente a la *columna Class* para asignar pesos *lógicos jerárquicos* (*Eco: 0, Eco Plus: 1, Business: 2*). Este método permite que el algoritmo interprete de forma matemática el orden de valor inherente en las distintas clases de viaje.
- *Mapeo Binario* (Binary Mapping): Implementado sobre la *variable objetivo satisfaction* para transformar las etiquetas de texto en un *formato binario* estructurado (*dissatisfied: 0, satisfied: 1*), optimizando la función de costo del clasificador.
- *Codificación One-Hot* (Dummies): Desplegado en las *variables nominales* restantes (*Customer Type* y *Type of Travel*) utilizando la función *pd.get\_dummies(drop\_first=True)*. La eliminación estratégica de la primera *columna (drop\_first)* previene matemáticamente la trampa de la *multicolinealidad* (falsa dependencia lineal entre variables artificiales).

# Executive Summary: Translating Data into Business Strategy

## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

### Feature Engineering & Target Balance: Categorical Encoding Strategies

#### Ingeniería de Características y Balance Objetivo: Estrategias de Codificación Categórica

#### Hyperparameter Optimization / Optimización de Hiperparámetros

| Tuning Hyperparameter / Hiperparámetro Ajustar | Search Space Matrix / Matriz de Búsqueda Explorable                                                                 | Cross-Validation / Validación Cruzada | Total Combinations / Combinaciones Evaluadas |
|------------------------------------------------|---------------------------------------------------------------------------------------------------------------------|---------------------------------------|----------------------------------------------|
| cv_params (max_depth / min_samples_leaf)       | max_depth: [4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, None]   min_samples_leaf: [1, 2, 3, 4, 5, 6, 7, 8, 9, 10] | 5-Fold Stratified CV (Pliegues)       | 1,380 Total Fits / Ajustes Totales en Grilla |

EN:

- Exhaustive Evaluation: Deployed *GridSearchCV* to evaluate 1,380 structural iterations, mathematically mapping hyperparameter trade-offs to mitigate overfitting risks.
- Cross-Validation Stability: Utilized 5-fold cross-validation to split training data into rotating validation blocks, ensuring the final metrics reflect structural generalizability.

ES:

- Evaluación Exhaustiva: Despliegue de *GridSearchCV* para evaluar 1,380 iteraciones estructurales, mapeando matemáticamente el comportamiento de los parámetros para mitigar el *sobreajuste* (overfitting).
- Estabilidad por Validación Cruzada: Uso de validación cruzada de 5 pliegues para dividir los datos en bloques rotativos de validación, asegurando que las métricas finales reflejen una capacidad de generalización real.

#### Feature Engineering Pipeline| Flujo de Ingeniería de Características

| Feature / Variable    | Variable Type / Tipo de Variable   | Transformation Method / Método de Transformación | Numerical Mapping / Mapeo Numérico          |
|-----------------------|------------------------------------|--------------------------------------------------|---------------------------------------------|
| satisfaction (Target) | Binary Target / Objetivo Binario   | Dictionary Mapping / Mapeo Directo               | {'dissatisfied': 0, 'satisfied': 1}         |
| Class                 | Ordinal Feature / Variable Ordinal | Ordinal Encoding / Codificación Ordinal          | {'Eco': 0, 'Eco Plus': 1, 'Business': 2}    |
| Customer Type         | Nominal Feature / Variable Nominal | One-Hot Encoding (get_dummies)                   | drop_first=True (Creates binary indicators) |
| Type of Travel        | Nominal Feature / Variable Nominal | One-Hot Encoding (get_dummies)                   | drop_first=True (Creates binary indicators) |

EN:

Prior to model training, a rigorous *feature engineering pipeline* was executed, specifically focusing on *categorical variable transformation*. Since *decision tree classifiers* in *scikit-learn* require strictly *numerical input matrices*, the conversion from text to numbers was performed using distinct strategies tailored to the mathematical nature of each attribute. This approach ensures both the *preservation of business hierarchies* and the statistical stability of the model.

- Ordinal Encoding: Applied specifically to the *Class* column to assign logical *hierarchical weights* (Eco: 0, Eco Plus: 1, Business: 2). This method allows the *algorithm* to *mathematically* interpret the inherent value order across different travel classes.
- Binary Mapping: Implemented on the target variable *satisfaction* to transform *text labels* into a structured *binary format* (dissatisfied: 0, satisfied: 1), optimizing the classifier's internal cost function calculation.
- One-Hot Encoding (Dummy Variables): Deployed across the remaining *nominal features* (Customer Type and Type of Travel) using the *pd.get\_dummies(..., drop\_first=True)* function. Strategically *dropping* the first category (*drop\_first*) mathematically prevents the *dummy variable trap* (multicollinearity among engineered indicators).

ES:

Antes de proceder con el *entrenamiento del modelo*, se implementó un flujo riguroso de *ingeniería de características* (feature engineering) enfocado en la *transformación de variables categóricas*. Dado que los clasificadores basados en *árboles de decisión* dentro de *scikit-learn* requieren matrices estrictamente *numéricas*, la *conversión de texto a número* se ejecutó utilizando enfoques diferenciados según la naturaleza matemática de cada atributo, garantizando la *preservación de jerarquías de negocio* y la estabilidad estadística del modelo.

- Codificación Ordinal (Ordinal Encoding): Aplicado específicamente a la *columna Class* para asignar pesos lógicos jerárquicos (Eco: 0, Eco Plus: 1, Business: 2). Este método permite que el algoritmo interprete de forma matemática el orden de valor inherente en las distintas clases de viaje.
- Mapeo Binario (Binary Mapping): Implementado sobre la *variable objetivo satisfaction* para transformar las etiquetas de texto en un *formato binario* estructurado (dissatisfied: 0, satisfied: 1), optimizando la función de costo del clasificador.
- Codificación One-Hot (Dummies): Desplegado en las *variables nominales* restantes (Customer Type y Type of Travel) utilizando la función *pd.get\_dummies(drop\_first=True)*. La eliminación estratégica de la primera *columna (drop\_first)* previene matemáticamente la trampa de la *multicolinealidad* (falsa dependencia lineal entre variables artificiales).

# Executive Summary: Translating Data into Business Strategy

## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

### Model Selection & Baseline Performance | Selección de Modelo y Rendimiento Base

#### Model Selection & Baseline Performance | Selección de Modelo y Rendimiento Base

| Classification Metric / Métrica de Clasificación | Baseline Value / Valor Base | Statistical Meaning / Significado Estadístico                                                                                  | Pipeline Context / Contexto del Flujo                                                                                                         |
|--------------------------------------------------|-----------------------------|--------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
| Accuracy / Exactitud Global                      | 93.56%                      | EN: Percentage of total correct classifications. / ES: Porcentaje total de clasificaciones correctas.                          | EN: Baseline performance across 32,372 test records. / ES: Rendimiento base sobre 32,372 registros de prueba.                                 |
| Precision / Precisión (Clase 1)                  | 94.03%                      | EN: Ability to avoid false positives (satisfied labels). / ES: Capacidad para evitar falsos positivos (etiquetas satisfechas). | EN: Measures reliability when predicting a satisfied passenger. / ES: Mide la confiabilidad al predecir un pasajero satisfecho.               |
| Recall / Exhaustividad (Clase 1)                 | 94.18%                      | EN: Ability to capture all actual positive records. / ES: Capacidad para capturar todos los registros positivos reales.        | EN: Minimizes false negatives, capturing unhappy clients effectively. / ES: Minimiza los falsos negativos, capturando clientes insatisfechos. |
| F1-Score / Puntuación F1                         | 94.11%                      | EN: Harmonic mean balancing precision and recall. / ES: Media armónica que equilibra precisión y exhaustividad.                | EN: Confirms solid baseline stability without geometric bias. / ES: Confirma una sólida estabilidad base sin sesgos geométricos.              |

#### Algorithm Strategic Defense / Defensa Estratégica del Algoritmo

- EN:
- Mathematical Invariance: *Decision trees* operate by *isolating descriptive partitions*, meaning features like *Flight Distance* or *Age* require *zero normalization* or *standardization*.
  - Interaction Mastery: The classifier automatically evaluates high-level service combinations (e.g., how *Travel Type* splits relative to *Seating Class*) without manual feature engineering.
- ES:
- Invarianza Matemática: Los *árboles de decisión* operan *aislando particiones descriptivas*, lo que significa que *variables* como *Distancia de Vuelo* o *Edad* requieren *cero normalización* o *estandarización*.
  - Dominio de Interacciones: El clasificador evalúa automáticamente combinaciones de servicios de alto nivel (ej. cómo influye el *Tipo de Viaje* según la *Clase de Asiento*) sin ingeniería manual.

#### Baseline Performance Metrics | Métricas de Rendimiento Base

| Classification Metric / Métrica de Clasificación | Baseline Value / Valor Base | Statistical Meaning / Significado Estadístico                                                                                  | Pipeline Context / Contexto del Flujo                                                                                                         |
|--------------------------------------------------|-----------------------------|--------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
| Accuracy / Exactitud Global                      | 93.56%                      | EN: Percentage of total correct classifications. / ES: Porcentaje total de clasificaciones correctas.                          | EN: Baseline performance across 32,372 test records. / ES: Rendimiento base sobre 32,372 registros de prueba.                                 |
| Precision / Precisión (Clase 1)                  | 94.03%                      | EN: Ability to avoid false positives (satisfied labels). / ES: Capacidad para evitar falsos positivos (etiquetas satisfechas). | EN: Measures reliability when predicting a satisfied passenger. / ES: Mide la confiabilidad al predecir un pasajero satisfecho.               |
| Recall / Exhaustividad (Clase 1)                 | 94.18%                      | EN: Ability to capture all actual positive records. / ES: Capacidad para capturar todos los registros positivos reales.        | EN: Minimizes false negatives, capturing unhappy clients effectively. / ES: Minimiza los falsos negativos, capturando clientes insatisfechos. |
| F1-Score / Puntuación F1                         | 94.11%                      | EN: Harmonic mean balancing precision and recall. / ES: Media armónica que equilibra precisión y exhaustividad.                | EN: Confirms solid baseline stability without geometric bias. / ES: Confirma una sólida estabilidad base sin sesgos geométricos.              |

- EN:
- Accuracy & F1-Score: Reached 93.56% Overall *Accuracy* and a balanced 94.11% *F1-Score* on default parameters, proving extreme structural robustness.
  - Precision & Recall: Achieved 94.03% Precision (*minimal false positive risk*) and 94.18% Recall (excellent sensitivity), establishing a high-performing benchmark before grid optimization.

- ES:
- Exactitud y F1-Score: Alcanzó 93.56% de Exactitud Global y un equilibrado 94.11% en *F1-Score* con parámetros por defecto, demostrando una alta robustez estructural.
  - Precisión y Exhaustividad: Obtuvo 94.03% de Precisión (mínimo riesgo de *falsos positivos*) y 94.18% de Exhaustividad (excelente sensibilidad), estableciendo un benchmark sólido antes de la optimización.

# Executive Summary: Translating Data into Business Strategy


## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

### Confusion Matrix Plot | Gráfico de Matriz de Confusión

### Hierarchical Logic Analysis / Análisis de la Lógica Jerárquica



#### Confusion Matrix Plot | Gráfico de Matriz de Confusión



From the generated *confusion matrix*, we can break down the model's predictions across the observations in the test set:

- True Negatives (TN): The model correctly classified dissatisfied passengers (0) as dissatisfied.
- True Positives (TP): The model correctly classified satisfied passengers (1) as satisfied.
- False Positives (FP): The model wrongly predicted that these passengers would be satisfied when they were actually dissatisfied (Type I Error).
- False Negatives (FN): The model wrongly predicted that these passengers would be dissatisfied when they were actually satisfied (Type II Error).

Conclusion: The heavy concentration of data along the main diagonal (top-left to bottom-right) confirms the high overall accuracy of the algorithm (0.97). The errors (False Positives and False Negatives) remain remarkably low and very evenly distributed, demonstrating a symmetric and well-balanced behavior of the classifier for both conditions.


ES:  
A partir de la matriz de confusión generada, podemos desglosar las predicciones del modelo sobre las observaciones del conjunto de prueba:

- Verdaderos Negativos (True Negatives - TN): El modelo clasificó correctamente a los pasajeros insatisfechos (0) como insatisfechos.
- Verdaderos Positivos (True Positives - TP): El modelo clasificó correctamente a los pasajeros satisfechos (1) como satisfechos.
- Falsos Positivos (False Positives - FP): El modelo predijo erróneamente que estos pasajeros estarían satisfechos cuando en realidad estaban insatisfechos (Error Tipo I).
- Falsos Negativos (False Negatives - FN): El modelo predijo erróneamente que estos pasajeros estarían insatisfechos cuando en realidad estaban satisfechos (Error Tipo II).

Conclusión: La fuerte concentración de datos en la diagonal principal (superior izquierda a inferior derecha) confirma la alta exactitud general del algoritmo (0.97). Los errores (Falsos Positivos y Falsos Negativos) se mantienen notablemente bajos y distribuidos de manera muy similar, lo que demuestra un comportamiento simétrico y equilibrado del clasificador para ambas condiciones.



#### Hierarchical Logic Analysis / Análisis de la Lógica Jerárquica



EN:  
• Root Supremacy: The top split points out that the algorithm selected operational features like flight services as the highest information gain drivers.  
• Mathematical Segmentation: Each descending path represents a series of strict binary IF-THEN rules, mapping the precise interaction thresholds that lead to a satisfied or dissatisfied outcome.

ES:  
• Supremacía de la Raíz: Los cortes superiores apuntan a que el algoritmo seleccionó características operativas como los servicios a bordo como los mayores impulsores de ganancia de información.  
• Segmentación Matemática: Cada camino descendente representa una serie de reglas binarias estrictas SI-ENTONCES, mapeando los umbrales de interacción precisos que definen el resultado.

| Tree Level / Nivel del Árbol & Split Metric  | Feature Highlight / Variable Destacada | Strategic Split Threshold / Umbral del Corte | Business Logic / Lógica Comercial                                                                                                   |
|----------------------------------------------|----------------------------------------|----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|
| Root Node / Nudo Raíz (Level 0)              | Inflight wifi service                  | Inflight Wifi > 0.5 (or similar)             | EN: The absolute primary discriminator for customer satisfaction. / ES: El discriminador primario absoluto de la satisfacción.      |
| Top Sub-nodes / Nodos Superiores (Level 1-2) | Type of Travel & Class                 | Categorical Encoded Boundaries               | EN: Segments business vs. personal travel priorities. / ES: Segmenta las prioridades de viajes de negocios frente a personales.     |
| Leaf Nodes / Nodos Hoja (Terminal)           | Final Class Predictions                | Pure/Mixed Samples (Entropy/Gini)            | EN: Deep branches capture specific, multi-layered service complaints. / ES: Ramas profundas capturan quejas de servicio multinivel. |

EN:  
• Granular Complexity: While the initial levels display clean strategic segments, the deep, dense lower layers reflect the complex non-linear combinations allowed by our max\_depth=16 constraint.  
• Generalization Balance: The structured leaf limitations prevent individual branches from over-memorizing noise, successfully isolating macro behavioral patterns across the survey rows.

ES:  
• Complejidad Granular: Mientras los niveles iniciales muestran segmentos estratégicos limpios, las capas inferiores densas reflejan las combinaciones no lineales complejas permitidas por el límite max\_depth=16.  
• Equilibrio de Generalización: Las limitaciones estructuradas en las hojas evitan que las ramas individuales memoricen ruido, aislando con éxito patrones macro de comportamiento.

# Executive Summary: Translating Data into Business Strategy

## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

### Grid Search Mechanics | Mecánica de la Búsqueda en Grilla

### Champion Parameter Selection / Selección de Parámetros Ganadores



#### Grid Search Mechanics | Mecánica de la Búsqueda en Grilla

EN:

- Automated Refitting: Evaluated the complete hyperparameter space utilizing 5-fold cross-validation. By setting refit='f1', the algorithm ranked all 1,380 combinations using the average F1-score to identify the optimal parameter weights.
- Generalization Layer: Cross-validation prevents the classifier from selecting parameters that simply memorize the training rows, enforcing strict performance boundaries on unseen data structures.

ES:

- Reajuste Automatizado: Evaluación del espacio completo de hiperparámetros utilizando validación cruzada de 5 pliegues. Al configurar refit='f1', el algoritmo clasificó las 1,380 combinaciones usando el F1-score promedio para identificar los pesos óptimos.
- Capa de Generalización: La validación cruzada evita que el clasificador seleccione parámetros que simplemente memoricen los datos de entrenamiento, imponiendo límites estrictos de rendimiento en estructuras no vistas.

| Grid Parameter / Parámetro de Grilla         | Exploration Range / Rango de Exploración             | Optimal Winner / Ganador Óptimo | Strategic Modeling Purpose / Propósito Estratégico del Ajuste                                                                                             |
|----------------------------------------------|------------------------------------------------------|---------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| max_depth (Profundidad Máxima)               | [4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, None] | 16                              | EN: Limits maximum vertical growth to avoid memorizing noisy rows. / ES: Limita el crecimiento vertical máximo para evitar memorizar ruido.               |
| min_samples_leaf (Muestras Mínimas por Hoja) | [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]                      | 9                               | EN: Enforces minimal sample size per terminal node to stabilize splits. / ES: Fuerza un tamaño muestral mínimo por nodo terminal para estabilizar cortes. |
| refit='f1' (Criterio de Reajuste)            | Harmonic mean balancing Precision and Recall         | Champion Model / Modelo Campeón | EN: Automatically retrains the final tree on full data using the top F1 score. / ES: Reentrena automáticamente el árbol con el F1-score más alto.         |



#### Champion Parameter Selection / Selección de Parámetros Ganadores

EN:

- The Optimal Frontier: The search matrix converged at max\_depth=16 and min\_samples\_leaf=9 as the top-performing operational setup for the classifier.
- Variance Control: Restricting depth to 16 limits vertical model complexity, while requiring 9 samples per leaf prevents the tree from overfitting on statistical noise, maximizing long-term predictive power.

ES:

- La Frontera Óptima: La matriz de búsqueda convergió en max\_depth=16 y min\_samples\_leaf=9 como la configuración operativa de mayor rendimiento para el clasificador.
- Control de Varianza: Restringir la profundidad a 16 limita la complejidad vertical del modelo, mientras que exigir 9 muestras por hoja evita que el árbol se sobreajuste al ruido estadístico, maximizando el poder predictivo.




#### Optimized Decision Tree Analysis Análisis del Árbol de Decisión Optimizado

Evaluating the top tiers of the "best" decision tree model reveals key operational insights:

- The Core Anchor (Inflight entertainment):**
  - The root node splits the entire dataset based on whether a passenger rates inflight entertainment. This confirms that no matter how much we tune the constraints, entertainment quality remains the primary gateway differentiator of passenger sentiment.
- Symmetric Secondary Priorities:**
  - When entertainment is low (): The model immediately pivots to evaluate Seat comfort (). If both comfort and entertainment are lacking, the passenger profile shifts heavily toward dissatisfied (the orange node on the left).
- When entertainment is high ():**
  - The model shifts focus to the digital experience, prioritizing Ease of Online booking (). Smooth digital interactions funnel passengers into a highly pure satisfied cluster (the deep blue node on the far right).

**Strategic Takeaway:** While hyperparameter tuning protects the model from memorizing noise deep within its branches (levels 4 through 16), the fundamental pillars of passenger satisfaction—Entertainment, Comfort, and Seamless Booking—are robust and remain completely unchanged at a macro level.



ES:

La evaluación de los niveles superiores del "mejor" modelo de árbol revela hallazgos operativos clave:

- El Pilar Central (Inflight entertainment):**
  - El nodo raíz divide todo el dataset basándose en si el pasajero califica el entretenimiento a bordo con una puntuación. Esto confirma que, independientemente de cuánto ajustemos las restricciones, la calidad del entretenimiento sigue siendo el diferenciador primario de la experiencia.
- Prioridades Secundarias Simétricas:**
  - Si el entretenimiento es bajo (): El modelo pivota de inmediato a evaluar la comodidad del asiento (Seat comfort). Si faltan tanto el entretenimiento como la comodidad, el perfil del pasajero cae drásticamente en el grupo de dissatisfied (el nodo naranja de la izquierda).
- Si el entretenimiento es alto ():**
  - El modelo se enfoca en la experiencia digital, priorizando la facilidad de la reserva en línea (Ease of Online booking). Una interacción digital fluida canaliza a los clientes hacia un grupo altamente puro de pasajeros satisfied (el nodo azul oscuro en el extremo derecho).

**Conclusión Estratégica:** Mientras que el ajuste de hiperparámetros protege al modelo de memorizar ruido en las profundidades de sus ramas (niveles 4 al 16), los pilares fundamentales que dictan la satisfacción —Entretenimiento, Comodidad y Reserva Digital— son sumamente robustos y se mantienen inalterados a nivel macro.

# Executive Summary: Translating Data into Business Strategy

## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

Análisis Costo-Beneficio y Justificación de Negocio (Control de Overfitting vs. Rendimiento).



**Cost-Benefit Analysis & Business Justification /**  
**Análisis Costo-Beneficio y Justificación de Negocio**

| Pipeline Phase / Fase del Pipeline      | Overall Accuracy / Exactitud Global | Model Precision / Precisión (Clase 1) | Structural Constraints / Restricciones Estructurales | Generalization Status / Estado de Generalización         |
|-----------------------------------------|-------------------------------------|---------------------------------------|------------------------------------------------------|----------------------------------------------------------|
| Baseline Tree / Árbol Base (Slide 5)    | 93.56%                              | 94.03%                                | Unconstrained (Libre)                                | High Overfitting Risk / Alto riesgo de memorizar ruido.  |
| Tuned Tree / Árbol Optimizado (Slide 7) | 93.85%                              | 95.13%                                | max_depth=16   min_samples_leaf=9                    | Optimized Boundary / Frontera robusta ante nuevos datos. |

EN:

- Strategic Optimization: Although the overall accuracy gain seems marginal (moving from 93.56% to 93.85%), the grid search successfully boosted Precision to a highly reliable 95.13%.
- Pruning Weak Branches: Enforcing max\_depth=16 and min\_samples\_leaf=9 effectively stops the tree from memorizing random statistical noise, ensuring the model generalizes seamlessly to new passenger rows.

ES:

- Optimización Estratégica: Aunque la ganancia en la exactitud global parece marginal (subiendo de 93.56% a 93.85%), la búsqueda en grilla elevó con éxito la Precisión a un altamente confiable 95.13%.
- Poda de Ramas Débiles: Imponer max\_depth=16 y min\_samples\_leaf=9 frena de manera efectiva la memorización de ruido estadístico, asegurando que el modelo generalice de forma óptima ante nuevos pasajeros.



**Investment Cost vs. Production Efficiency /**  
**Inversión vs. Eficiencia en Producción**

EN:

- One-Time Development Expense: Evaluating 1,380 iterations via cross-validation represented a temporary computational cost, isolating all processing heavy-lifting strictly within the training pipeline.
- Instant Deployment: Once the optimal parameters are discovered, the resulting champion architecture is streamlined, structurally healthier, and executes corporate CRM predictions instantly.

ES:

- Gasto de Desarrollo Único: Evaluar 1,380 iteraciones mediante validación cruzada representó un costo computacional temporal, aislando el esfuerzo de procesamiento estrictamente dentro de la etapa de desarrollo.
- Despliegue Instantáneo: Una vez descubiertos los parámetros óptimos, la arquitectura campeona resultante es simplificada, estructuralmente más sana y ejecuta predicciones de CRM de forma instantánea.

# Executive Summary: Translating Data into Business Strategy

## Resumen Ejecutivo: Transformando Datos en Estrategia de Negocio

### Strategic Conclusions & Operational Impact / Conclusiones Estratégicas e Impacto Operativo



### Strategic Conclusions & Operational Impact / Conclusiones Estratégicas e Impacto Operativo

| Strategic Pillar / Pilar Estratégico     | Data-Driven Discovery / Hallazgo Basado en Datos                                    | Operational Action Plan / Plan de Acción Operativo                                                                                                    | Key Performance Indicator / KPI de Control                              |
|------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------|
| Digital Comfort / Confort Digital        | Inflight Wifi Service was selected as the root node for passenger splits.           | EN: Upgrade fleet routers and launch high-bandwidth connectivity packages. / ES: Modernizar routers de la flota y lanzar planes de alta velocidad.    | Satisfaction Lift / Incremento en Satisfacción del Cliente (+5% target) |
| Physical Experience / Experiencia Física | Seat Comfort and Inflight Entertainment act as the primary sub-level failure modes. | EN: Audit seating ergonomics and overhaul older cabin multimedia hardware. / ES: Auditar ergonomía de asientos y renovar hardware multimedia antiguo. | Net Promoter Score (NPS) / Índice de Recomendación Net Promoter Score   |

- EN:
- Data-Driven Prioritization: The decision tree mathematically proves that digital features (like Wifi) and cabin comfort carry significantly more weight in passenger retention than baseline metrics like flight distance.
  - Proactive Churn Defense: Transitioning from reactive complaint management to a predictive CRM allows the airline to identify and salvage potentially dissatisfied passenger segments before they abandon the brand.
- ES:
- Priorización Basada en Datos: El árbol de decisión demuestra matemáticamente que las características digitales (como el Wifi) y el confort en cabina tienen un peso significativamente mayor en la retención que métricas tradicionales como la distancia del vuelo.
  - Defensa Proactiva del Cliente: Pasar de una gestión de quejas reactiva a un CRM predictivo permite a la aerolínea identificar y rescatar segmentos de pasajeros potencialmente insatisfechos antes de que abandonen la marca.



### Technical Next Steps / Próximos Pasos Técnicos

- EN:
- Model Deployment & Monitoring: Push the tuned champion model into production, establishing continuous monitoring pipelines to detect feature drift as passenger behavioral patterns evolve.
  - Unstructured Data Integration: Future pipeline iterations should incorporate NLP sentiment analysis from text-based reviews to complement the existing structured survey features.
- ES:
- Despliegue y Monitoreo del Modelo: Desplegar el modelo campeón ajustado en producción, estableciendo flujos de monitoreo continuo para detectar desvíos de datos (data drift) a medida que los patrones de comportamiento evolucionen.
  - Integración de Datos No Estructurados: Las futuras iteraciones del pipeline deberían incorporar análisis de sentimiento (NLP) a partir de reseñas de texto para complementar las variables estructuradas de la encuesta.